Predicción de Colelitiasis — Dataset UCI

Nicolas Rodriguez Forero & Fabian Rincón Suarez

---

1. Introducción

La colelitiasis (cálculos biliares) afecta al 10–15 % de la población adulta y puede derivar en colecistitis, pancreatitis biliar o sepsis. Su diagnóstico requiere ecografía, recurso no siempre disponible de inmediato. Este trabajo entrena modelos de clasificación sobre variables clínicas y bioquímicas de rutina para **priorizar pacientes con alto riesgo**, apoyando la decisión médica en entornos con capacidad diagnóstica limitada.

`Gallstone Status = 0` → sano · `Gallstone Status = 1` → enfermo **(clase positiva clínica)**

---

2. Dataset, Exploración y Preprocesamiento

319 registros · 38 predictoras · sin valores faltantes · distribución 50/50 División estratificada: **255 train / 64 test** (`random_state=123`).

El análisis exploratorio (sobre train) revela los principales factores diferenciadores:

- **Composición corporal:** IMC, grasa visceral (VFA) y acumulación hepática de grasa (HFA) son consistentemente superiores en pacientes enfermos.
- **Perfil lipídico:** triglicéridos y LDL elevados, HDL reducido en clase 1 — coherente con saturación biliar de colesterol.
- **Género y comorbilidades:** las mujeres y los pacientes con diabetes mellitus o hiperlipidemia presentan mayor prevalencia de cálculos.
- **Correlaciones:** se identificaron grupos de alta multicolinealidad (TBW/ECW/ICW, masa muscular/ósea), justificando la eliminación de 11 variables redundantes.

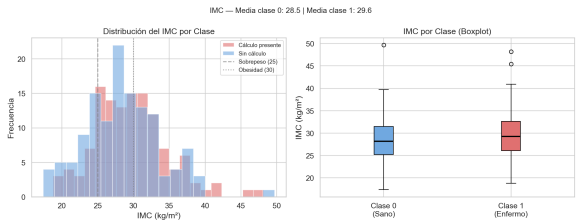

Figure 1: Exploración: IMC y perfil lipídico por clase

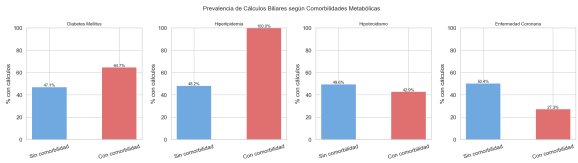

Figure 2: Comorbilidades y correlaciones

Preprocesamiento (sin data leakage — parámetros calculados solo sobre train): - 27 de 38 variables retenidas por relevancia clínica y baja redundancia. - Winsorización P1–P99 para outliers extremos en variables bioquímicas. - `StandardScaler` sobre las 21 variables continuas; binarias sin escalar.

Métrica prioritaria: el **Recall de clase 1**. Un falso negativo (enfermo no detectado) implica riesgo grave; un falso positivo genera únicamente una ecografía adicional.

---

3. Evaluación de Modelos

Validación cruzada estratificada **k=5** sobre train; evaluación final única sobre test.

Validación cruzada — media ± std (5 folds):

Modelo	Accuracy	Recall	F1	ROC-AUC
DummyClassifier	0.506 ± 0.008	0.000 ± 0.000	0.000 ± 0.000	0.500 ± 0.000
Regresión Logística	0.765 ± 0.039	**0.722 ± 0.068**	0.751 ± 0.048	**0.841 ± 0.041**
Random Forest	0.753 ± 0.040	0.698 ± 0.092	0.733 ± 0.056	0.834 ± 0.025
Gradient Boosting	0.761 ± 0.029	0.714 ± 0.087	0.745 ± 0.041	0.833 ± 0.019
SVM	0.698 ± 0.027	0.667 ± 0.053	0.685 ± 0.033	0.773 ± 0.042

Evaluación sobre test:

Modelo	Accuracy	Recall (cl. 1)	Precision (cl. 1)	F1 (cl. 1)	ROC-AUC
DummyClassifier	0.500	0.000	0.000	0.000	0.500
Regresión Logística	0.703	0.719	0.697	0.708	0.816
Random Forest	**0.750**	**0.719**	**0.767**	**0.742**	**0.844**
Gradient Boosting	0.719	0.656	0.750	0.700	0.839
SVM	0.703	0.656	0.724	0.689	0.783

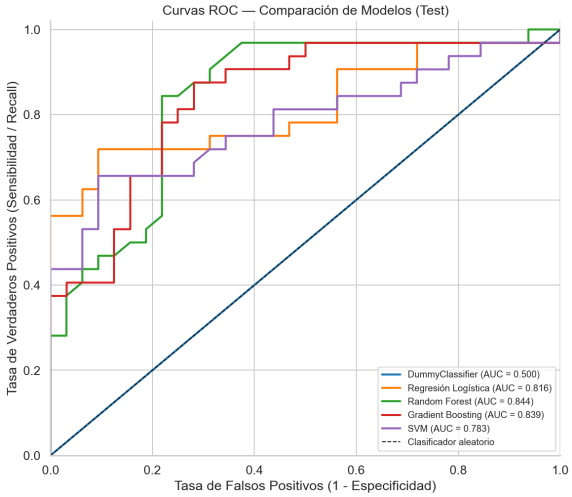

Figure 3: Curvas ROC y matrices de confusión

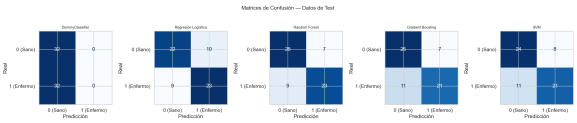

Figure 4: Matrices de confusión

El **Random Forest** alcanza el mejor perfil global: mayor accuracy (75 %), mayor precisión para enfermos (76.7 %) y mayor ROC-AUC (0.844), con el mismo recall que la Regresión Logística (71.9 %) pero con **menos falsos positivos** (7 vs. 10 sobre 64 pacientes). Las variables de mayor importancia — IMC, VFA, HFA, triglicéridos, TBFR — coinciden con los factores de riesgo clínicamente reconocidos.

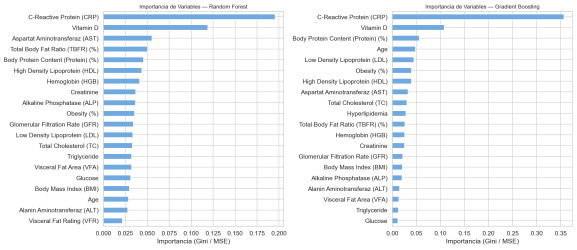

Figure 5: Importancia de variables — Random Forest y Gradient Boosting

---

4. Conclusiones e Impacto Clínico

Modelo recomendado: Random Forest. La Regresión Logística es la alternativa cuando se requiere interpretabilidad directa de coeficientes.

Impacto estimado en una cohorte de 100 pacientes (50 % prevalencia):

Escenario	Enfermos detectados	No detectados (riesgo)	Ecografías innecesarias
Sin modelo — derivar todos	50	0	**50**
DummyClassifier	0	**50 — riesgo grave**	0
Random Forest	**~36**	~14	**~12**

El modelo **no reemplaza la ecografía**, pero permite reducir en ~75 % las derivaciones innecesarias con una tasa de detección del 72 %. Es directamente aplicable como herramienta de triaje en atención primaria o en sistemas con lista de espera para diagnóstico por imagen.

Limitaciones: muestra pequeña (319 registros); umbral de decisión no optimizado (reducirlo a 0.3–0.4 aumenta recall asumiendo más falsos positivos); validación externa pendiente antes de cualquier implementación clínica real.